

COMPONENTĂ PROIECT:
Fișierul/fișierele de intrare (format csv/txt)
Studiul propriu-zis, document word/pdf, având pe prima pagină TITLUL PROIECTULUI, cu una din temele de mai jos (la alegere) și realizat după cerințele specificate. În studiu va fi specificată sursa datelor.
Proiectul Python (PyCharm, Visual Studio Code etc.)

A. Clusterizare

Vor fi aplicate următoarele modele de clasificare nesupervizată:

1. Modele de tip partiționare - KMeans, BisectingKMeans, KMedoids
2. Modele de tip probabilistic - Amestec Gaussian (EM)
3. Modele ierarhice - Ward, Legătură completă, Legătură simplă, Media legăturilor, Centroid
4. Modele bazate pe densitate - DBSCAN, OPTICS, HDBSCAN
5. Modele grid - STING, DENCLUE, CLIQUE

Pentru fiecare model vor fi calculate cel puțin două partiții folosind criteriile Elbow inerție, Elbow ierarhic, Silhouette, Calinski–Harabasz, Davies–Bouldin, BIC, AIC în funcție de model.

Outputuri generate

- Grafice Elbow pentru alegerea numărului de clusteri (pe bază de inerții sau distanțe) dacă este cazul și în funcție de model
- Metrice de validare internă generale (scoruri de calitate ale partițiilor): Silhouette, Calinski–Harabasz, Davies–Bouldin. Scorul Silhouette va fi calculat în forma generală, ca medie a clusterilor și în formă ajustată logaritm (logaritm sau radical din logaritm).
- Scoruri Silhouette la nivel de instanță
- Grafice Silhouette pentru fiecare partiție
- Grafice bidimensionale pentru fiecare partiție. Vor fi folosite ca axe de reprezentare componentele principale, componentele independente sau componente de scalare multidimensională.
- Grafice dendrogramă pentru fiecare partiție ierarhică
- Grafice de analiză clusteri pentru fiecare partiție. Vor fi folosite grafice de tip histogramă, distribuție, box sau orice alt tip de grafic ce ilustrează structura clusterilor.
- Partițiile sub formă de tabel, liste, dicționare sau orice altă formă din care să rezulte din ce cluster al partiției face parte fiecare instanță
- Ordonarea partițiilor folosind criterii precum Silhouette (general, mediu, ajustat), Calinski–Harabasz, Davies–Bouldin. Criteriul de ordonare este la liberă alegere. Poate fi creat un criteriu sintetic pe baza criteriilor menționate.
- Comentarii textuale privind partițiile formate pe baza analizei histogramelor/distribuțiilor clusterilor

Toate outputurile și comentariile vor fi integrate în studiul realizat word/pdf, nu vor fi prezentate ca fișiere separate.

B. Clasificare

Vor fi aplicate următoarele metode, în funcție de tipul datelor de intrare:

- Clasificare Bayesiană cu estimator parametric Gaussian

- Clasificare Bayesiană cu estimator neparametric kernel sau categorial (histograme)
- Clasificarea liniară
- Arbori de decizie
- Ansambluri - Random Forest
- Ansambluri - Bagging
- Ansambluri - AdaBoost
- SVM liniar
- SVM Gaussian
- kNN
- Regresia logistică

Etapele analizei

1. Evaluarea predictorilor folosind metodele de evaluare prezentate la curs/seminar
2. Antrenarea modelelor pe setul de antrenare
3. Evaluarea modelelor pe setul de testare conform metricilor prezentate la curs/seminar
4. Aplicarea celui mai bun model pe setul de aplicare

Outputuri

- Tabele cu rezultatele filtrării predictorilor. Vor fi prezentate scoruri, teste, ranguri și vor fi eliminate (dacă se consideră necesar) anumite variabile predictor.
- Predicțiile în setul de testare
- Indicatorii de acuratețe
- Matricea de confuzie - tabel + grafic
- Arborele de decizie - grafic
- Tabele cu erori de clasificare în setul de testare
- Grafice de robustețe: ROC, Lift, Gain
- Importanța atributelor pentru arbori de decizie și Random Forest - grafic + tabel
- Plot distribuție comparativă în două dimensiuni a instanțelor bine clasificate și mal-clasificate. Vor fi folosite pentru scalarea bidimensională PCA sau MDS.
- Predicția în setul de aplicare

C. Reducerea dimensionalității

Metode

- Analiza în componente principale
- Analiza factorială
- Non-Negative Matrix Factorization(NMF)
- Analiza componentelor independente
- Kernel PCA
- Scalarea multidimensională
- Încorporarea stohastică a vecinilor folosind distribuția t (tSNE)

Analiza va avea două direcții:

- *Reducerea dimensională* prin selectarea unui număr redus de componente cât mai reprezentative în concordanță cu specificul modelului aplicat
- *Interpretabilitatea* noilor dimensiuni

Numărul de dimensiuni va fi stabilit în funcție de model, aplicând criterii specifice acolo unde este cazul (Elbow).

Interpretabilitatea se va baza pe outputuri de tip grafic sau tabele de date care scot în evidență: scoruri, varianțe, corelații componente-variabile observate, comunalități, entropia (informația mutuală), distanțe în spațiul instanțelor (inclusiv corelarea distanțelor).

Opțional, pentru instanțe care reprezintă unități spațiale, pot fi prezentate hărți ale rezultatelor menționate mai sus (de exemplu hărți de scoruri).

D. Studiul asocierilor

Model	Output
Apriori	Tabelul regulilor cu indicatorii calculați (lift, confidence, support)